

TGVF Stage1: 从“可读 D ”到“有用 D ” (续)

RP66 答案效用实证与新目标消融结论

TGVF Project

实证结果与 RL 决策更新, 2026 年 7 月 30 日

摘要

本文是 2026 年 7 月 28 日《TGVF Stage1: 从“可读 D ”到“有用 D ”》的实证续篇。前文的准确结论是“RP66 的 evidence readout 很强, 但答案效用尚未被证明”, 并预注册了 image-only、correct/zero/wrong- D 、 D -only 与 direct replacement 的配对验证。本次在固定的 V4 test first-200 (46 个 image groups) 上完成该验证: 五个 Qwen3-VL-8B-Instruct Stage1 候选各生成 10 个 arms, 共 10,000 条记录。

原始 RP66 (E0) 在 image-only 下为 72.5%, image+ D^+ 为 83.5%, 原始增益 +11.0pp; 控制相同协议后, image+ D^+ 相对 image+ D^0 与 image+ D^- 仍分别提升 +7.5pp 与 +6.5pp, 配对 exact p 分别为 0.0081 与 0.0241。 D -only 的 correct/zero/wrong 为 65.5%/35.0%/55.0%, 说明 D 自身携带答案相关信息; 但 direct- D replacement 仅 49.0%, 比原图低 23.5pp, 且只比 matched-wrong D 高 3.0pp ($p = 0.461$)。因此 D 已被证明是有效的目标聚焦补充表示, 而不是完整原图的替代品。

四个 matched-budget 500-step 候选 E0C/E2/E3/E4 的 image+ D^+ 分别为 83.0%/83.5%/82.0%/83.0%, 均未超过 E0。训练 loss 确实下降、生成 token 也发生变化, 但 held-out correctness 几乎不变, 说明新增 clean-answer 与 counterfactual branch 没有创造额外效用; 它们主要帮助我们以正确评测发现 RP66 已有能力。当前证据仍是 oracle-target-conditioned D utility, 并使用诊断性盲评 overlay, 不能直接等价于 policy 会选择工具、生成正确 D 或获得端到端 RL 增益。

关键词: TGVF; Stage1; answer utility; paired counterfactual; RP66; Instruct; RL data selection

1 相对前文的结论更新

前文区分了 evidence readability、答案充分性与答案增量效用, 并明确禁止把 18-row RP46/Thinking replacement smoke 外推到 RP66/Instruct。此次实验补齐了当时缺失的正式 paired generation。结论更新不是“旧判断被推翻”, 而是把“尚未证明”推进为以下三层结果:

1. **增量效用成立:** 在原图存在时, 正确 D 提供稳定且显著的额外答题信息;
2. **替代效用不成立:** 移除原图后, D 不足以恢复完整视觉能力;
3. **新目标无额外收益:** 500-step answer/counterfactual 训练没有超过原始 RP66。

2 实验合同与可复现身份

2.1 固定模型、样本与十臂评测

E0 是 production RP66 step-2000, 而非虚构的 private baseline; 其 Adapter SHA-256 为 3429dc83880d...65ce5c9。E0C/E2/E3/E4 均

表 1: 十臂评测及其识别问题。

Context	Arms	识别量
Image	image-only	原始能力
D -only	zero, correct, wrong	D 自身信息与 specificity
Image+ D	zero, correct, wrong	部署相关的增量效用
Direct replace	zero, correct, wrong	D 是否可替代原图

从该 exact artifact warm-start。五个候选使用完全相同的 ordered first-200 manifest (46 groups; VG/TextVQA/DocVQA/TextOCR/ChartQA 分别为 84/38/31/25/22 rows; SHA-256 55e2cde5e118...34d8), greedy decoding, 64-token cap 与 EOS 151645/151643 均固定。E0C 的 8 个互斥 shards 按同一 candidate 合并为 200 rows, 无重复或遗漏。

每个 sample 的 D materialization 始终读取原始未修改问题; 短答案 instruction 只加在无梯度的 answer reader 评测端, 不改变 Stage1 权重或 reasoning 能力。所有 D arm 原子交换 main D 与 DeepStack 8/16/24。matched-wrong D 来自同图不同 target, 且规范化答案必须不同, 避免“wrong D 实际支持同一答案”。

2.2 评分与边界

保守 scorer v3 只自动接受完整、可规范化的答案; 自然语言中无法安全 exact-match 的结果交给 blind Qwen2.5-72B-Instruct judge。10,000 条记录中 2,851 条由 deterministic scorer 判定, 7,149 条 unresolved 去重为 1,986 个 blind requests。judge payload 只含 question、candidate、reference 与 task kind, 不含 checkpoint、arm 或 D 身份。

overlay 的固定 claim scope 是 diagnostic_semantic_overlay_not_formal_pilot。因此本文的 p 值是给定该盲评标签后的 paired exact 统计, 不应写成已完成独立人工复核。generation 本身则逐记录原子提交、可恢复, 并绑定实现、配置、样本和 artifact hashes。

3 RP66 E0: D 的真实答案效用

3.1 十臂准确率

表 2 给出 E0 的全部结果。三个现象同时成立: correct D 在每种 context 下都明显优于 zero; 只有 image+ D 达到并超过原图; direct replacement 的 correct/wrong 差距很小。

为避免把“增加 token/工具协议”误认为 D 内容增益, 定义三个量:

$$\Delta_{\text{raw}} = \text{Acc}(I, D^+) - \text{Acc}(I), \quad (1)$$

Updated empirical contract. 同一批 200 个 held-out samples 上, $\text{Acc}(I, Q) = 72.5\%$; $\text{Acc}(I, Q, D^+) = 83.5\%$; $\text{Acc}(I, Q, D^0) = 76.0\%$; $\text{Acc}(I, Q, D^-) = 77.0\%$ 。因此正确内容的受控增益为 $+7.5 \text{ pp}$ (vs. zero) 与 $+6.5 \text{ pp}$ (vs. wrong)。另一方面, fresh D -only 为 65.5% , direct replacement 为 49.0% 。最符合数据的机制不是“ D 重建整幅图”, 而是“ D 在原图全局上下文上增加 target-focused residual evidence”。

图 1: 本次实证对 Stage1 utility contract 的更新。

表 2: E0 在 first-200 上的 semantic accuracy。

Context	Zero	Correct	Wrong
D -only	35.0%	65.5%	55.0%
Image+ D	76.0%	83.5%	77.0%
Direct replace	22.0%	49.0%	46.0%
Image-only	72.5%		

表 3: E0 的配对效应。W/L/T 为 treatment-only correct, control-only correct 与 ties; p 为双侧 exact 检验。

Treatment vs. control	Δ	W/L/T	p
Image+ D^+ vs. image-only	+11.0 pp	34/12/154	0.0016
Image+ D^+ vs. image+ D^0	+7.5 pp	22/7/171	0.0081
Image+ D^+ vs. image+ D^-	+6.5 pp	21/8/171	0.0241
D -only D^+ vs. D^0	+30.5 pp	67/6/127	$< 10^{-13}$
D -only D^+ vs. D^-	+10.5 pp	32/11/157	0.0019
Direct D^+ vs. image-only	-23.5 pp	12/59/129	$< 10^{-7}$
Direct D^+ vs. D^-	+3.0 pp	26/20/154	0.461

$$\Delta_{\text{content}} = \text{Acc}(I, D^+) - \text{Acc}(I, D^0), \quad (2)$$

$$\Delta_{\text{spec}} = \text{Acc}(I, D^+) - \text{Acc}(I, D^-). \quad (3)$$

E0 的三者分别为 $+11.0 \text{ pp}$ 、 $+7.5 \text{ pp}$ 与 $+6.5 \text{ pp}$ 。zero/wrong 本身相对 image-only 的 $+3.5/ +4.5 \text{ pp}$ 提醒我们: 原始 $+11 \text{ pp}$ 不能全部归因于正确语义; 但两个控制后的增益仍为正且达到配对显著。

表 3 的统计由 immutable overlay records 中的 final scores post-hoc 计算, 报告 row-level、双侧、未作多重校正的 exact 检验; 同一 image group 内的 rows 可能相关。以 46 个 image groups 为 cluster 做 sign-flip sensitivity 后, 前三个主比较的 p 分别为 0.0050、0.0155 与 0.0232, 方向不变。统计证据因此足以支持诊断结论, 但仍不替代更大样本与正式 judge/human adjudication。

3.2 机制解释: 互补而非替代

D -only 的 65.5% 低于 image-only 的 72.5% , 但远高于 zero 与 wrong, 说明它压缩了大量答案相关的 target evidence, 同时丢失了部分全局布局、背景关系、文本邻域或 reader 熟悉的原图分布。image+ D 同时保留全局 context 与聚焦 residual, 因而达到 83.5% 。direct replacement 既移除全局视觉, 又迫使 reader 把 target-focused representation 当作完整图像, 属于更强的分布外干预; 它失败并不否定 additive utility。

这也解释了旧 replacement smoke 与新结果为何可以同时为真: 旧实验测试“充分性”, 本次主实验测试“在部署 context 下的边际贡献”。对 RL 而言, 只要实际协议是 image+ D , 主指标应是 additive controlled gain, 而不是要求 D 独立重建原图能力。

4 500-step 新目标: 没有额外增益

4.1 Matched-budget 训练网络

四个 private candidates 均只更新 TGVF Adapter; Qwen、vision tower、merger 与 decoder 冻结。训练使用相同的 500 optimizer steps、16

表 4: 实际完成的 500-step cells。

Cell	Answer context	Answer	CF
E0C	none, legacy continuation	no	no
E2	fresh D -only, clean	yes	no
E3	gold-evidence answer context	yes	zero/wrong
E4	fresh D -only, clean	yes	zero/wrong

表 5: 五个候选的 held-out utility。Image-only 固定为 72.5% ; W/L/T 是 image+ D^+ 相对 E0。

Cell	D -only	Image+ D	Direct	Raw Δ	W/L/T
E0	65.5%	83.5%	49.0%	+11.0 pp	—
E0C	64.5%	83.0%	49.0%	+10.5 pp	0/1/199
E2	65.5%	83.5%	49.0%	+11.0 pp	1/1/198
E3	65.5%	82.0%	49.5%	+9.5 pp	0/3/197
E4	65.5%	83.0%	49.5%	+10.5 pp	1/2/197

rows/update、constant 10^{-6} 、同一 accepted sample sequence 和 fresh AdamW。E0C 是 unchanged legacy objective 的 matched-budget continuation; E2 是无 gold evidence 的 fresh D -only clean-answer loss; E3 是含 gold evidence 的 leakage-diagnostic answer+counterfactual; E4 是 clean answer+zero/wrong counterfactual 的主候选。

训练目标确实被优化: first-25 到 last-25 的 mean answer NLL 在 E2/E3/E4 分别由 11.396/5.627/11.392 降至 10.772/5.095/10.816; E3/E4 的 zero comparison loss 分别下降 0.261/0.281。四个最终 Adapter SHA-256 均不同, 因此下游持平不是复用了同一个文件。

4.2 候选级结果与 paired flips

E2 与 E0 在主指标上完全持平; E0C/E4 低 0.5 pp , E3 低 1.5 pp 。所有候选相对 E0 的 discordant pairs 极少且 exact $p \geq 0.25$, 不能声称真实退化, 但也没有任何正向 promotion signal。另一方面, image+ D^+ 的生成 token 序列相对 E0 只在 153-164/200 rows 完全一致, 说明训练确实改变了自由生成行为; 变化主要没有跨越 correctness boundary。

因此“新目标没有增益”不是 checkpoint 未加载、样本不一致或 evaluator 固定输出造成的假象。更合理的解释是: RP66 在 oracle-target、image+ D 条件下已经有较强效用, 而 uniformly applied 的 500-step answer losses 主要改变了 NLL/措辞, 没有提高 held-out 0-1 utility。当前不应把 E2/E3/E4 任一 cell promotion 为新的 production Stage1。

5 为何训练前没有判定 RP66 已有效

最关键的概念错误是把“ D 单独不够”误写成“ D 没有用”。target-focused residual 的合理目标本来就是补充原图, 而不是复制原图。其次, 18-row 下 $6.5\text{--}7.5 \text{ pp}$ 的真实效应只对应约一个样本, correct/wrong 排名很容易被方差翻转。前文因此谨慎写成“RP66 utility 尚未被证明”, 而不是“RP66 无效”; 本次实验正是完成

表 6: 旧证据与本次证据回答的是不同问题。

缺口	旧证据 → 本次修正
干预问题 控制臂	direct replacement (充分性) → image+ D (边际贡献) 无完整 additive controls → correct/zero/matched-wrong
样本量	RP46 smoke 18 rows → RP66 paired first-200
模型域	Thinking/RP46 → production RP66/Instruct
评分	自然输出易漏判 → conservative v3 + blind judge
视觉协议	未固定完整合同 → main 与 8/16/24 原子交换
证据类型	evidence readout → free-generation answer utility

该未决项。

6 对 Stage1、数据筛选与 RL 的更新

6.1 Stage1 决策

当前应保留 production RP66 E0 作为 Instruct Stage1 默认值, 暂不长训 E2/E3/E4。若继续改 Stage1, 目标不应再是对所有样本统一增加 answer NLL, 而应先识别确有 marginal utility 的 rows, 再优化 sample-level correct-vs-zero/wrong advantage。更大 held-out set、task slices 与多次 judge/人工复核应先于 2,000-step 扩展。

前文 G2/G3 的方向与幅度在本次 diagnostic first-200 上均通过: D -only correct 显著胜 zero/wrong, image+ D 的受控增益也超过 +2 pp。但前文建议的 formal gate 是至少 500 rows, 且当前 judge config 尚未被接受为 formal Pilot judge, 所以只能标记为**强诊断性通过**, 不能悄然改写为最终 production certification。

6.2 T1U 与 RL 的真正剩余问题

本次消除了“即使 D 正确也完全无用”的主要风险, 却没有消除以下风险: policy 是否调用工具、target/trajectory 是否正确、实际生成的 D 是否达到 oracle condition, 以及错误调用的成本。换言之, 已经验证的是

正确 target 与正确 D 条件下, image+ D 比 image 更准; 尚未验证的是自由 rollout 中端到端 P (correct answer) 是否上升。

下一阶段应固定为:

1. 用 E0 构建 T1U paired selector, 保留 image+ D^+ 相对 zero/wrong 真正获益的 rows;
2. 报告 self-selected target、tool success、 D validity 与 conditional answer gain 的分解;
3. Crop reproduction 继续作为 oracle visual positive control;

4. 低学习率 RL 比较 R0 no-tool、R1 real- D 与 R2 sham/wrong- D ;
5. tool bonus 依赖 real-vs-sham answer advantage, 而不是仅依赖 tool call 或最终答对。

首轮 RL 仍适合 BS16×n8×80-step、decoder LoRA、frozen TGVF 与 10^{-6} 起点。当前结果支持进入小预算、强对照的 RL 可行性验证, 不支持直接扩大训练或把 oracle +11 pp 当作可实现的端到端收益。

7 结论与证据索引

本次最重要的新结论是: **RP66** 原本已经产生有答案效用的 D , 但该效用主要表现为与原图互补, 而非替代原图。image+ D^+ 的 raw gain 为 +11.0 pp; 控制协议与错误内容后仍保留 +6.5-7.5 pp 的 target-specific gain。旧 replacement failure 继续成立, 却不再能支持“ D 无效”的判断。

E0C/E2/E3/E4 没有带来可检测的额外增益。新训练帮助建立了更严格的因果问题和 evaluator, 但没有提供更好的 checkpoint。未来工作的中心应从“再造一个可读 D ”转为“筛选什么时候 D 有边际效用, 并验证 policy 能否可靠取得这项效用”。

范围边界。 本文只报告 RP66 Qwen3-VL-8B-Instruct 线, 不是历史 REP-QWEN3-V4-CONTEXTUAL-V4 Thinking Stage1 的新正式评测。正确 D 使用 oracle target/trajectory; answer instruction 只用于无梯度评测; semantic overlay 是 diagnostic blind judge, 而非人工 gold adjudication。

证据身份。 Generation roots 位于 artifacts/representation_experiments/answer_utility/evaluation/formal_first200_short_reader_v2_score_v3_10arm_20260730/。Semantic summary 位于其 sibling semantic_rescore/formal_first200_5candidate_10arm_shortreader_v2_scorev3_qwen25_72b_20260730/summary.json。Overlay run identity 为 ea4a094f076e...971f, manifest SHA-256 为 76fe4f86230c...ba9e; summary/records SHA-256 分别为 1f3e30577838...ccd1e 与 8c7b0c8818e4...6367f。配置与 isolated implementation 位于 configs/representation/experiments/answer_utility/ 与 src/tgvf_rl/representation/experiments/answer_utility/。