

TGVF Stage1: 从“可读 D ”到“有用 D ”

答案效用、因果约束与 RL 准入门槛

TGVF Project

设计决策与实施报告, 2026 年 7 月 28 日

摘要

本文审计迁移到 Qwen3-VL-8B-Instruct 后的 TGVF representation phase (Stage1), 并回答一个先于 RL 的核心问题: 工具 observation D 是否真的提高最终答题能力。当前最终 Instruct artifact RP66 已在 200-row internal evaluation 中取得 correct- D evidence mean NLL 1.235; correct- D 对 target-only、random- D 、wrong-same-image- D 与 wrong-different-image- D 的胜率分别为 100%、100%、95.5% 与 88.6%。这些结果证明 D 可被 frozen reader 读取并具有 target specificity, 但不证明自由答题增益。相反, 36-pair native target-presence 诊断的 actual-direction accuracy 为 0, 历史 RP46/Thinking 的 18-row replacement smoke 中 correct- D 也明显低于 image-only 与 matched-wrong- D , 表明 evidence readability 与 answer utility 可以断裂。

根因是目标失配。现行 Stage1 仅优化 evidence-token L_{gen} 、同图 $K \times K$ Matrix CE 与 Norm; short answer、EOS 和 free generation 均无梯度。训练集中 23,694/39,998 (59.24%) 的 evidence_description 直接包含 short_answer 子串, 因此不能简单打开当前 transcript 尾部的 answer labels: 答案会看到 gold evidence, 且当前 original-image key block 只覆盖 evidence query。

本文据此提出冻结 Instruct reader 的 answer-utility Stage1: 用不含 gold evidence 的 fresh D -only 与 native image+ D 两种 context, 直接优化正确答案 likelihood, 并要求 correct D 严格优于 zero/sham 与 matched-wrong D 。T1 继续负责筛选全错/全对的直接难度样本, 但新增 T1U utility gate; 只有 real- D 同时优于 image-only 与 sham/wrong- D 的样本才作为 TGVF-RL tool-positive 数据。Crop 复现保持为第一条独立实验线, 同时充当 TGVF 的 oracle positive control。只有 held-out paired generation gate 通过后, 才启动 real- D /sham- D /no-tool 的低学习率 RL 对照。

关键词: TGVF; Stage1; answer utility; counterfactual; Instruct; data selection; policy RL

1 问题定义与固定方向

项目已从 Thinking policy 转向 Qwen3-VL-8B-Instruct, 并把数据筛选作为 RL 方法的一部分。实验保持两条线及其顺序:

1. **复现 Crop RL:** 在 coordinate/crop bug 修复后建立有效 Crop baseline; 此前损坏的 run 不能用于判断 RL。
2. **改进 TGVF reward:** 只有 Instruct 数据、 D utility 与优化门槛明确后才进入该线。

真正需要证明的不是“能否从 D 复述 teacher evidence”, 而是两个因果量。替代效用移除答案阶段的原

表 1: RP66 的固定训练配置。

项目	设置
Base reader	Qwen3-VL-8B-Instruct
Trainable	TGVF Adapter only
Target provider	contextual hidden, layer -1
Observation	main D + layers 8/16/24
Same-image group	$K = 4$
World / global rows	2 GPU / 32 per update
Max pixels	262,144 (512×512)
Optimizer	AdamW, initial 10^{-4}
Schedule / steps	cosine, warmup 100 / 2,000
Objective weights	Matrix 1, Gen 1, Norm 0.1
Manifold	disabled, weight 0
Leakage warning	false

图及所有 image-seen cache:

$$\Delta_{\text{rep}} = \text{Acc}(Q, z, D^+) - \text{Acc}(Q, z, D_{\text{ctl}}). \quad (1)$$

增量效用固定原图、prompt 与 decoding, 只交换工具 observation:

$$\Delta_{\text{add}} = \text{Acc}(I, Q, z, D^+) - \text{Acc}(I, Q, z, D_{\text{ctl}}). \quad (2)$$

若 RL 使用 image+ D , 式 (2) 是主指标; 式 (1) 则证明 D 自身承载答案相关视觉信息。控制项包括 zero/sham D 、同图不同 target 的 real D 、同 target 不同图的 real D 与 shuffled-source D 。

2 RP66: 已知证据与结论边界

2.1 Artifact 与固定配置

当前最终 Instruct artifact 为

RP-66-qwen3-instruct-balanced-t1-
contextual-2000-gpu01

状态 complete。表 1 给出关键配置。

2.2 Evidence readout 与 semantic diagnostic

表 2 汇总同一份 200-row/46-group internal evaluation。correct- D evidence readout 很强, query retrieval Top-1/Top-2 为 87.0%/97.0%, MRR 0.929, mean diagonal gap 2.434。它证明代理任务已学会, 但不是 answer accuracy。

2.3 历史 replacement 反例

历史 18-row direct replacement 使用 RP46/Thinking, 不是 RP66/Instruct; 它不能外推为当前正式结果, 却给出了“代理目标成功但 QA utility 失败”的直接反例(表 3)。correct- D 对 image-only 为 1 win/9 losses/7 ties/1 unclear; 对 wrong- D 为 0/6/11/1。

因此当前准确结论是: **RP66 的 D utility 尚未被证明**, 而不是“RP66 已被证明无效”。第一项新实验

Stage1 utility contract. $[I, Q] \rightarrow \text{oracle/native tool target } z \rightarrow \text{TGVF}(I, z) \rightarrow (D^{(0)}, D^{(8)}, D^{(16)}, D^{(24)}) \rightarrow \text{answer}$
 $a + \text{EOS}$. 新 answer branch 不含 gold evidence_description. D -only 路径创建 fresh context, 移除原图 token、原图 DeepStack 与所有已读取原图的 pre- D KV; native image+ D 路径保持部署协议, 只原子交换 main D 与全部 DeepStack branches. 训练首轮冻结完整 Instruct reader, 只更新 TGVF Adapter.

图 1: 从 evidence reconstruction 转向 answer utility 后的监督边界与信息路径。

表 2: RP66 的 evidence readout、representation health 与语义方向诊断。前六项是代理任务成功证据; 后两项暴露“可读但未必有用”的风险。

证据	数值	能说明什么	不能说明什么
Correct- D evidence mean NLL	1.235	Gold evidence 在 correct D 下可读	不是 answer NLL/accuracy
Target-only / random- D NLL	4.114 / 4.033	D 不只是空条件	仍可能编码 teacher evidence
Correct 胜 target-only / random	100% / 100%	readout 明显依赖 D	不证明 free generation 采用 D
Correct 胜 wrong-same / different	95.5% / 88.6%	target-specific readout 较强	不证明正确语义方向
Query Top-1 / Top-2 / MRR	87.0% / 97.0% / 0.929	同图 target 区分较强	可能利用 identity code
D /source norm ratio	1.284 / 2.858 / 2.303 / 2.223	main 与 8/16/24 均 finite、无 collapse	Norm 不约束视觉语义
Target-presence direction	0/36	语义方向存在明确断裂信号	小审计集不是 QA benchmark
Target-presence continuation	5/36 (13.9%)	autonomous continuation 很弱	仍需更大专门测试

表 3: RP46/Thinking direct- D replacement smoke.

Arm	C/I/U	Accuracy
Image-only	14/3/1	77.8-83.3%
Zero- D	0/18/0	0%
Correct- D	6/11/1	33.3-38.9%
Matched-wrong- D	12/5/1	66.7-72.2%

必须是 RP66/Instruct 的 paired utility evaluation, 不能直接开始 TGVF-RL。

3 现行 Stage1 的目标失配

3.1 答案从未进入训练目标

现行目标严格为

$$\mathcal{L}_{\text{old}} = \mathcal{L}_{\text{matrix}} + \mathcal{L}_{\text{evidence}} + 0.1\mathcal{L}_{\text{norm}}. \quad (3)$$

completed transcript 虽含 evidence 与 short answer, 但 label mapping 只覆盖 evidence span; answer、separator、EOS、prompt 与 wrapper 均为 -100。冻结 Qwen 本身不是错误; 错误在于经 frozen Qwen 传回 Adapter 的梯度只来自 teacher evidence。

3.2 不能只打开当前 answer labels

对 39,998-row train split 做 casefold exact-substring 审计, 23,694 rows (59.24%) 的 evidence_description 包含 short_answer; target 包含 short answer 的比例虽只有 195/39,998 (0.49%), 仍需 hard-fail。若直接解除当前 answer mask, 答案会读取 gold evidence; 同时 original-image key block 只覆盖 evidence query, 答案仍可能从原图或 image-conditioned KV 取信息。因此必须建立独立、无 gold evidence 的 answer transcript, 并为 replacement 创建 fresh context。

表 4: 现行 objective 的实际约束与缺口。

项	实际约束	缺口
L_{evidence}	复述 teacher evidence	无 answer/EOS/free generation
L_{matrix}	同图 target 检索	可用 identity/text code 取巧
L_{norm}	表示数值尺度	不约束语义与 utility
Answer loss	无	short answer 无梯度
Causal contrast	无	不要求 correct 胜 zero/wrong

3.3 Target-valued soft-prompt 风险

当前 bidirectional Adapter 先令 target attend visual, 再令 visual attend enriched target; 后一步 value 来自 target side:

$$C_T = \text{Attn}(T, V, V), \quad (4)$$

$$\tilde{T} = \text{LN}(T + C_T), \quad (5)$$

$$C_V = \text{Attn}(V, \tilde{T}, \tilde{T}), \quad (6)$$

$$\hat{V} = V + G \odot W_{\Delta} C_V. \quad (7)$$

这允许 target 不只选择区域, 还向视觉 token 写入语言/身份码。Matrix CE 会奖励 target 可分性, 却不要求 value 来自图像。强 counterfactual 应固定 Q, z , 只改变局部视觉值; 若 loss-only 仍取巧, 再将 target 限制为 salience/gating, 约束 D value 主要来自 source visual token, 并限制 residual ratio。

4 Answer-Utility Stage1

4.1 冻结 reader 的答案分数

令 $D_i = A_\theta(V(I_i), H(Q_i, z_i))$, 冻结 Instruct reader ϕ . 在不含 gold evidence 的部署同构 context $C_i(D)$ 中, 定义含真实 EOS 的长度归一化答案分数:

$$s_i(D) = \frac{1}{|a_i \oplus \text{EOS}|} \log p_\phi(a_i \oplus \text{EOS} | C_i(D)). \quad (8)$$

MCQ 使用正确选项相对其它选项的 log-odds; 开放答案使用规范化 alias 与 matched wrong values, 而不只使用裸 NLL.

4.2 主目标与反事实

$$\mathcal{L}_{\text{ans}} = -\frac{1}{B} \sum_i s_i(D_i^+), \quad (9)$$

$$\mathcal{L}_{\text{gain}} = \frac{1}{B} \sum_i \text{softplus}(m - [s_i(D_i^+) - s_i(D_i^0)]), \quad (10)$$

$$\mathcal{L}_{\text{cf}} = \frac{1}{|\mathcal{N}|} \sum_{i,c} \text{softplus}(m - [s_i(D_i^+) - s_i(D_{i,c}^-)]). \quad (11)$$

建议 smoke 起点为

$$\begin{aligned} \mathcal{L}_{\text{new}} = & \mathcal{L}_{\text{ans}} + \mathcal{L}_{\text{gain}} + \mathcal{L}_{\text{cf}} \\ & + 0.25\mathcal{L}_{\text{evidence}} + 0.25\mathcal{L}_{\text{matrix}} + 0.1\mathcal{L}_{\text{norm}}. \end{aligned} \quad (12)$$

权重不是最终默认值; 实现后必须比较各项 value、valid-row count 与 Adapter gradient norm. evidence/Matrix 降为可解释性与 target specificity 的辅助目标, 不再决定 promotion.

主要 real negatives 包括: 同图不同 target; 同 target 不同图且答案不同; 同一 Q, z 只改变局部 value 的 edit pair; shuffled source; target-only/no-image. zero D 仅作 OOD health control. 每次必须原子交换 main D 与 layers 8/16/24, 保持 shape、grid、M-RoPE、mask、dtype、token count 与 prompt 一致; negative 在其对应 row 中也应是 positive, 避免模型学习“坏 lane marker”。

4.3 训练范围与条件升级

第一阶段只训练 TGVF main/DeepStack Adapter, 冻结 vision tower、merger、decoder、embedding 与 LM head. 冻结 reader 是识别 drop-in utility 的实验控制, 避免 LM 与 D 共同形成私有编码。

只有 D -only 通过而 image+ D 失败时, 才进入 Stage1.5: 冻结 TGVF, 训练 very narrow reader-LoRA, 并使用 real/sham pair loss、direct replay、KL retention 及 matched direct-only LoRA control. D -only 未通过时不启用 reader-LoRA, 不 full-tune vision tower, 也不让 RL 更新 TGVF。

5 T1U 数据筛选与 Crop 对照

5.1 T1 只测难度

当前 T1 对每个 candidate 做 8 次 Instruct full-image direct rollout: 0/8 排除过难, 8/8 排除过易, 1-7/8 保留。它只测直接答题难度与 headroom, 不测工具 utility, 不能自动等价于 tool_needed。

表 5: T1 后的 T1U paired arms。

Arm	条件	用途
A	Image-only direct	原始基线
B	Image + real correct D	实际增量效用
C	Image + zero/sham D	协议与 token 对照
D	Image + matched-wrong D	语义因果对照
E	Image + oracle crop	工具上界/positive control
F	D -only correct/zero/wrong	D 自身充分性

表 6: 统一初始化、数据、seed 与预算的 objective ablation。

Cell	Objective	用途
E0	现有 Matrix/evidence/norm	代理目标 baseline
E1	E0 + answer NLL	测直接答案梯度
E2	E1 + zero/wrong margins + value CF	主因果方案
E3	E2 + narrow reader-LoRA	仅在 additive 失败时

5.2 二次 utility gate

对 T1 candidate 使用完全配对的六臂评估 (表 5)。tool-positive 必须满足 real- D arm B 同时优于 direct A 和 sham/wrong C/D。无增益或有害 rows 应作为 no-tool negatives, 而不是静态 teacher tool hint。

低成本筛选分数可定义为

$$u_i = \min\{s_i(D^+) - s_i(D^0), s_i(D^+) - s_i(D^-)\}. \quad (13)$$

先以 teacher-forced answer score 筛选, 再用 free generation 复核; 最终 test split 不参与选择。

Crop 线保持独立复现, 同时承担四个角色: oracle positive control; 工具增益上界; 在 crop>direct rows 上蒸馏 answer logits/hidden states; 必要时作为 visual-manifold teacher. 若 crop 有益而 D 无益, 定位为 Stage1/TGVF; 若二者均无益, 先修数据/模型工具接口, 而不是调 RL reward。

6 实验矩阵与 Promotion Gate

6.1 最小 ablation

已有 oracle_d_utility.py 定义 image-only、zero/correct/wrong replacement、 D -only 与 image+ D arms. 第一步是解除 Thinking-only guard, 支持 RP66 Instruct, 并在 256-500 个 held-out rows 上补齐 paired baseline。

可先用 RP66 warm-start 做 64-row、100-300-step implementation smoke; 正式 E0/E1/E2 各跑 500 steps, 胜者再跑 2,000。按 RP66 4.4-4.8 s/step 与新目标约 2.25 倍 train core 粗估, E2 500-step 为 1.2-1.5 h, 2,000-step 为 5-6 h, 另加 free generation; 前 20-50 steps 后必须重新校准。

6.2 不可绕过的准入门槛

诊断顺序固定为: oracle crop/text evidence 是否提升; 若提升, correct D 是否优于 zero/wrong; 若仍提升, image+ D 是否优于 image-only。三步

表 7: Stage1 promotion gate. 正式 generation gate 建议至少 500 held-out rows, 使用 paired bootstrap CI 与 McNemar correct-only/reverse-only.

Gate	必须满足	统计合同	未通过时
G0 完整性	无 answer/evidence leakage; matched geometry; DeepStack 原子交换; 部署同构	manifest 与 layout proof	修实现
G1 likelihood	correct 相对 zero 与 wrong 的 Δ 均为正	bootstrap 95% CI lower > 0	不长训
G2 D -only	$\text{Acc}(D^+) > \text{Acc}(D^0), \text{Acc}(D^-)$	win rate > 60%; CI lower > 50%	D 本体失败
G3 additive	image+ D^+ 高于 image-only 与 sham/wrong	至少 +2 pp; paired CI 不跨 0	不进入 TGVF-RL
G4 no-harm	direct-correct 子集退化不超过 1 pp; 切片与 seeds 同方向	OCR/chart/counting/spatial 报告	重筛数据/改接口
G5 readout	若保留解释性, evidence readout 下降不超过约 5%	与 RP66 同 evaluator	调辅助权重
G6 RL 准入	G1-G5 全过, 且 real-vs-wrong win/loss $\gtrsim 1.5$	预注册阈值	Crop 线继续, TGVF-RL 暂停

分别定位数据/模型上界、Adapter grounding 与 reader/protocol integration。不能让 RL 承担前两步的修复。

7 RL: 只奖励可测工具增益

当前 reward 在最终答对且 observation 成功时给 conditional tool bonus, 奖励的是调用与答对的相关性, 而非 D 导致的增益。旧 Stage3 虽改善 Stage2 Free accuracy, 但 vision/TGVF 冻结、只更新语言侧 LoRA, 且 tool subset 未显示稳定增益; 它不能证明 D utility。

第一版使用离线实测 u_i 与 call cost:

$$R = R_{\text{answer}} + \beta \mathbb{I}(\text{tool}) u_i - c_{\text{call}}. \quad (14)$$

预算允许时, 在部分 rollout 做 real/sham paired replay:

$$R_{\text{tool}} = \beta[r(\text{real } D) - r(\text{sham } D)] - c_{\text{call}}. \quad (15)$$

real 与 sham 都答对时不提供因果工具 bonus。RL 至少比较 R0 no-tool/direct, R1 real TGVF 与 R2 sham/zero/wrong tool; R1 – R2 才是 tool-specific gain。

首轮沿用适于验证的 BS16×n8×80-step geometry, 只训练 decoder LoRA, TGVF 冻结; 学习率从无可靠参照的 10^{-5} 降到历史成功 Stage3 的保守量级, 优先 10^{-6} 再做小网格。不要同时改变 full/LoRA、分辨率、reward 和数据。

8 实施顺序与结论

现有 streaming scorer 已能通过 frozen 8B reader 对 D 做 VJP 并回传 Adapter; counterfactual 与 atomic main/DeepStack swap 也已有实现基础。需要新增独立 answer-only schema、fresh/native 两类 row builder、answer/counterfactual VJP、objective-v4 配置、Instruct oracle evaluator、T1U selector 与 RL real-vs-sham reward。

执行顺序冻结为:

1. port RP66/Instruct utility evaluator, $N = 256-500$;
2. 实现 answer-only fresh D -only 与 native image+ D ;

3. E0/E1/E2 同预算 500-step ablation;
4. 仅通过 G0-G5 的 E2 跑 2,000 steps;
5. T1U 区分 tool-positive 与 no-tool/harmful rows;
6. Crop reproduction/positive control 独立继续;
7. 低 LR 比较 R0 no-tool, R1 real- D , R2 sham- D ;
8. 只有 D -only 通过、additive 失败时做 reader-LoRA; 只有干净 loss/data 仍失败时做 Adapter v2。

最终交付标准不再是 evidence reconstruction。Stage1 必须在完全配对、无 gold evidence、部署同构的条件下, 使 correct D 对答案的增益显著高于 zero/wrong D , 并在 image+ D 下超过 image-only。只有这一因果效用门槛成立, TGVF reward 的 RL 改进才有明确优化对象; 否则 RL 更可能放大调用偏好、协议长度或幻觉。

结论边界。 RP66 readout 是 Instruct 结果, 18-row replacement 是 RP46/Thinking 结果; 36-pair target-presence 只是 failure detector。本文的 loss 权重、margin 与 gate 数值是预注册起点, 必须以统一预算 ablation 验证。尚未完成 RP66 正式 image-only/real- D /sham- D generation, 因此不得写成“RP66 已无效”。

证据索引。 RP66 配置见 configs/representation/qwen3_instruct_balanced_t1_contextual_2000step_gpu01.toml; 训练与 internal evaluation 见 artifact 目录中的 metrics.jsonl 与 internal_evaluation_v4_golden_audited_grounding_report.json。Evidence labels 位于 src/tgvf_rl/representation/training/transcript.py; image-key block 位于 streaming.py; Adapter target-valued delta 位于 src/tgvf_rl/representation/adapter.py; T1 与 RL 审计见 docs/POLICY_RL_DATA_SELECTION.md 和 docs/POLICY_RL_FUTURE_DIRECTION_20260728.md。