

TGVF Representation Phase:

原生工具条件下的目标特异视觉表征与初步 Grounding 验证

TGVF Project

实现与验证报告, 2026 年 7 月 21 日

摘要

本文报告 TGVF 新管线中的 representation phase (历史项目中曾称 Stage1) 的当前方法、训练实现与验证证据。该阶段不训练回答策略, 而是在冻结 Qwen3-VL-8B-Thinking 的条件下, 仅训练 TGVF Adapter, 使工具观察 D 同时满足两项义务: 包含目标相关信息, 并能被冻结语言模型因果读取。原生轨迹严格采用 Qwen 工具格式: 原图与问题进入 user turn, assistant 生成目标并调用 `tgvf_focus_tool`, tool turn 注入主 D 与三个 D-DeepStack 分支, 最后由 Qwen 读取并生成 evidence。训练使用同图多 target 的 $K \times K$ Matrix CE、对角 evidence 可读性损失 L_{gen} 以及固定历史 Norm 项; 默认 Matrix CE 以 evidence-token mean NLL 构造 Balanced score, 避免 evidence 长度直接改变 cell 尺度。

五个 2,000-step checkpoint 在完全一致的 200-row/46-group internal evaluation 上比较。Balanced $T = 1$ 、contextual hidden state、完整 D-DeepStack 的配置虽然同分布 Top-1 (82.5%) 略低于若干对照, 但取得最大的 mean diagonal gap (2.431) 与 wrong-same-image advantage (4.643), 并在 audited cross-image direction flip (5/9) 和 target-presence continuation (39/72) 上领先。target-token embedding、legacy summed-NLL、 $T = 0.1$ 及 main- D -only 分别暴露了 conditioning、score calibration 与 DeepStack 的必要性。

必须强调: 当前 hallucination 验证只有 36 个手工审计的同图正/负 target pair 与 9 个跨图 pair, 标签先验、严格字符串抽取和 teacher-forced/free-generation 不一致仍会影响结论。该套测试适合作为轻量 failure detector 与模型选择证据, 不能证明 target hallucination 已被解决, 也不是规范 benchmark。项目后续需要单独设计并审计 hallucination evaluation; 本文只明确该限制, 不在当前阶段新增或冻结测试方案。

关键词: TGVF; representation phase; Matrix CE; D-DeepStack; target grounding; hallucination

1 问题定义与范围

给定原图 I 、问题 Q 与工具调用目标文本 z , TGVF Adapter 学习一个目标条件视觉观察

$$\mathcal{D}_\theta(I, z) = (D^{(0)}, \{D^{(8)}, D^{(16)}, D^{(24)}\}), \quad (1)$$

其中主 D 替换 tool-response image block 的视觉 embedding, 三个 D-DeepStack 分支在 Qwen3-VL 原生层 8, 16, 24 注入。 D 不是 RGB crop, 也不是自然语言摘要, 而是保持原图视觉 token 布局的连续 latent observation。

该阶段有两个彼此独立、不能相互替代的目标:

- 1. Target specificity:** 对同一图像, $\mathcal{D}(I, z_a)$ 应区别于 $\mathcal{D}(I, z_b)$, 并承载与 z_a 而非泛化整图相关的证据;

- 2. Causal readability:** 冻结 Qwen 在读取正确 D 后应更容易恢复 evidence, 并应优于 matched wrong- D 、random- D 和 no- D 控制。

本文只讨论 representation phase。policy RL phase 仍从原始 Qwen reasoning policy 初始化; 这里训练出的 TGVF Adapter 在首轮 GRPO pilot 中冻结。历史 TGVF Adapter checkpoint 仅作参考, 本报告中的 checkpoint 均从 fresh random Adapter initialization 开始训练。

2 原生数据与监督协议

训练数据来自固定的 v4 clean-imend focus split: 39,998 条 train rows; 统一 post-hoc internal evaluation 使用同一数据版本的 867-row test split。每行必须提供非空 Q, z, e, a , 其中 e 是 evidence_description, a 是 short_answer。结构化 choice metadata 保留在 sample identity 中, 但不会追加到 user prompt。

Qwen chat template 生成的目标 span、evidence span 和两处视觉 placeholder 均通过 tokenizer offset 与 canonical-to-processor expansion 显式绑定。tokenizer 长度保持 151,669, 不新增协议 token, 也不 resize embedding 或 LM head。初始 prompt identity 为 qwen3-representation-image-question-v1, 其 user 文本严格等于 Q ; 不存在额外 target tutorial 或强制 focus 指令。

令 evidence token index 集合为 $\mathcal{E}_i$ 。训练对 causal shift 后的这些位置计算 NLL; 其它所有位置标签均为 -100。这使 L_{gen} 直接回答“冻结 reader 能否从 D 读出 evidence”, 而不是让 Adapter 学习复述 target 或最终答案。

3 TGVF Adapter

3.1 Target conditioning

当前接口实现两种 provider。默认选择 contextual hidden state: 从冻结 Qwen 完整原生 action transcript 的 target span 读取最后一层 hidden states, 记为 H_z 。对照 provider 直接读取同一 target token IDs 的 input embeddings。两者共享相同的 target-span proof、TGVF Adapter、数据顺序与训练超参数; provider identity 写入 artifact, 不能在 checkpoint 加载时替换。

3.2 双向 target-vision conditioning

冻结 vision tower 为原图产生主 pre-merge token $V^{(0)}$ 与三个 DeepStack pre-merge token $V^{(\ell)}, \ell \in \{8, 16, 24\}$ 。主路和每个分支拥有独立的双向 attention module。省略 branch 上标后, 计算可写为

$$T = W_T \text{LN}(H_z), \quad X = W_X \text{LN}(V), \quad (2)$$

$$C_T = \text{Attn}(W_Q^T T, W_K^V X, W_V^V X), \quad (3)$$

Native representation trajectory. $[I, Q] \rightarrow \text{assistant pre-reasoning} \rightarrow \text{tgvf_focus_tool}(\text{target}=z) \rightarrow \text{tool response } [D^{(0)}, \{D^{(8)}, D^{(16)}, D^{(24)}\}] \rightarrow \text{assistant post-}D \text{ reasoning } e \rightarrow \text{answer } a$. User turn 只含原图与原始问题; target 只出现在 assistant 的原生 tool call 中。训练 label 只覆盖 post- D 的 evidence_description token; 问题、tool-call JSON、tool response、答案和 template wrapper 均为 ignore index。Evidence query 对原图视觉 key 使用显式 block mask, 因此 loss 不能绕过 D 直接重读原图。

图 1: Representation phase 的原生轨迹、监督边界和信息路径。

$$\tilde{T} = \text{LN}(T + C_T), \quad (4)$$

$$C_V = \text{Attn}(W_Q^V X, W_K^T \tilde{T}, W_V^T \tilde{T}), \quad (5)$$

$$G = \sigma(W_G[\text{LN}(V); C_V]), \quad (6)$$

$$\hat{V} = V + G \odot W_\Delta C_V. \quad (7)$$

这里 $\text{Attn}(Q, K, V) = \text{softmax}(QK^\top / \sqrt{d})V$ 。最后, $\hat{V}$ 经过对应的、永久冻结的 Qwen visual merger 投影到 language width:

$$D^{(\ell)} = M_{\text{frozen}}^{(\ell)}(\hat{V}^{(\ell)}). \quad (8)$$

merger 属于冻结 Qwen, 不进入 Adapter artifact; 可训练参数只有 target/vision attention、gated residual 等 Adapter-owned tensors。main- D -only ablation 保留原图原生 DeepStack, 但把学习到的 D-DeepStack observation 分支置零, 因此它只检验主 D 的贡献。

4 训练目标

4.1 同图 Matrix CE

一个训练 group 包含同图 $K = 4$ 个不同 targets。矩阵第 (i, j) 个 cell 保持 row i 的问题、target context 与 evidence 不变, 但注入 column j 生成的完整 observation $\mathcal{D}(I, z_j)$; 主 D 与三个 D-DeepStack 分支必须作为原子整体交换。定义

$$N_{ij} = \sum_{t \in \mathcal{E}_i} -\log p_0(e_{i,t} | I, Q_i, z_i, \mathcal{D}_j, e_{i,<t}), \quad (9)$$

$$m_i = |\mathcal{E}_i|. \quad (10)$$

其中 p_0 是冻结 Qwen reader。默认 Balanced Matrix CE 使用

$$s_{ij} = -\frac{N_{ij}/m_i}{T},$$

$$\ell_i = -\log \frac{e^{s_{ii}}}{\sum_j e^{s_{ij}}}, \quad (11)$$

$$\mathcal{L}_{\text{mat}} = \frac{1}{\sum_g K_g} \sum_g \sum_{i=1}^{K_g} \ell_i.$$

默认 $T = 1$ 。legacy mode 则使用 $s_{ij} = -N_{ij}$, 保留历史 summed-NLL 行为。Balanced score 去除 evidence length 对 cell 尺度的直接影响; temperature 只缩放 logits 与梯度锐度, 不改变 cell 排序。全局 reduction 在所有 rank 与 accumulation microsteps 上先累加 numerator 和 valid-row count, 再除一次; rank-local mean 的等权平均是错误实现。

4.2 Readability 与 Norm

对角 observation 的 evidence-token mean NLL 定义为

$$\mathcal{L}_{\text{gen}} = \frac{1}{B} \sum_i \frac{N_{ii}}{m_i}. \quad (12)$$

它和 Matrix CE 共享对角 forward, 但作用不同: 前者优化绝对可读性, 后者优化同图相对 target specificity。

表 1: Representation phase 的固定训练配置。

项目	设置
Base model	Qwen3-VL-8B-Thinking
Trainable	TGVF Adapter only
Precision/attention	BF16 / SDPA
Max pixels	$512 \times 512 = 262,144$
Same-image group	$K = 4$
Per-rank batch / world	4/2
Gradient accumulation	4
Global rows/update	32
Optimizer	AdamW, 10^{-4}
Betas / weight decay	(0.9, 0.999)/0.01
Schedule	cosine, warmup 100
Minimum LR ratio	0.1
Steps / seed	2,000 / 42
Grad norm clip	1.0
Validation/checkpoint	every 500 steps

唯一允许的 Norm 项比较每个 D token 与对应 source path 的平均 token norm:

$$\mathcal{L}_{\text{norm}}(D, V) = \text{mean}_t \left[\log \frac{\|D_t\|_2 + 10^{-6}}{\max_s (\text{mean}_s \|V_s\|_2, 10^{-6})} \right]^2. \quad (13)$$

三个分支先平均, 再与 main loss 平均; V detach。最终目标为

$$\mathcal{L} = \mathcal{L}_{\text{mat}} + \mathcal{L}_{\text{gen}} + 0.1\mathcal{L}_{\text{norm}}. \quad (14)$$

visual-token manifold loss 权重严格为 0; 本阶段没有 margin, symmetric CE、embedding contrastive 或其它隐藏目标。

5 训练实现与配置

表 1 给出五个 2,000-step checkpoint 共享的 formal geometry。冻结 Qwen 仅作为 deterministic feature producer 与 causal reader; 两卡 FSDP2 只 shard TGVF Adapter 所在模型结构, reshard_after_forward=false。同图 sampler 保证每个 microbatch 是完整 $K = 4$ group; 普通 row shuffle 不满足 Matrix CE 语义。

实现同时保留 normal autograd 与 streaming/manual-gradient 路径。后者逐 cell 计算 frozen-Qwen logits, 释放 reader graph, 并把全局 Matrix-CE cell gradient 重新传播到每个 Adapter candidate; 测试要求 Balanced/legacy value、manual/autograd gradient、不同 evidence 长度以及全局 row reduction 一致。严格 checkpoint 覆盖 Adapter、optimizer、scheduler、sampler、RNG、FSDP shard 与 validation history, 并只在 optimizer boundary 保存。

6 统一 Internal Evaluation

6.1 协议

五个 checkpoint 全部使用同一个 v4 clean-imend test manifest、同一 Qwen/chat template、

seed 42 和相同 evaluation runner: 200 rows、46 个同图 groups; 9 个 audited cross-image pairs; 36 个 audited same-image positive/negative target-presence pairs。因而表 2 与表 3 可直接横向比较。

同图 query matrix 使用 evidence mean NLL, 报告 Top-1、MRR 与 diagonal gap。readout 另外比较 correct D 、target-only、deterministic random D 、wrong-same-image D 与 wrong-different-image D 。internal evaluator 对 evidence query 屏蔽原图视觉 keys, 避免 correct- D NLL 被原图 shortcut 掩盖。

跨图测试保持 question/target 固定, 只交换来自两张不同图的完整 D , 检查 value a 对 value b 的 teacher-forced log-odds 是否随 observation 正确翻转, 并进行 D-only greedy continuation。target-presence 测试则在同一张图上构造经人工审计的存在 target z^+ 与明显不存在 target z^- , 定义

$$r(D) = \log p(y_P | D) - \log p(y_N | D), \quad (15)$$

$$\Delta_{\text{presence}} = r(D^+) - r(D^-), \quad (16)$$

其中 $y_P = \text{PRESENT}$, $y_N = \text{NOT_PRESENT}$ 。正的 Δ_{presence} 表示正 target observation 比负 target observation 更支持“存在”; 负值是 target hallucination 的危险信号, 但不是经过校准的绝对概率。

6.2 五个 checkpoint

为简洁起见, C-T1 表示 Balanced $T = 1/\text{contextual/full D-DeepStack}$; E-T1 把 provider 改为 target-token embedding; C-Legacy 使用 summed-NLL; C-Main 关闭学习到的 D-DeepStack; C-T0.1 只把 Balanced temperature 改为 0.1。

6.3 结果解释

Contextual conditioning 是必要证据。 C-T1 相对 E-T1 将 Top-1 从 70.5% 提升至 82.5%, mean gap 从 0.773 提升至 2.431, presence separation 从 -2.283 翻转到 +0.407。两者 correct- D NLL 接近, 说明差异主要不是 evidence 的一般语言可读性, 而是 target condition 是否携带足够的上下文语义。

Balanced $T = 1$ 比单看排名更可靠。 C-Legacy 与 C-T0.1 的 Top-1 分别为 86.0% 和 85.5%, 表面上高于 C-T1; 但其 mean gap 只有 0.308/0.419, cross flip 仅 1/9, presence separation 均为负。Top-1 只要求 correct cell 略胜, 无法反映 margin、因果翻转或不存在 target 的错误注入。Balanced $T = 1$ 因而保留为默认, 而非追逐单一 retrieval accuracy。

D-DeepStack 承载丰富语义。 C-Main 在简单 presence separation (+0.958) 与 cross flip (5/9) 上不差, 说明主 D 可以表达某些粗粒度存在性; 然而其 Top-1 降到随机附近的 50.0%, mean gap 为 0.053, target continuation 仅 6/72。完整 D-DeepStack 不是装饰性旁路, 而是同图 target discrimination 与具体 evidence readout 的主要组成。

Norm 不是质量代理。 五个 checkpoint 均无 token-collapse warning。C-T1 的 main D /source mean norm ratio 为 1.265, 三个分支为 2.342/2.706/2.020; C-Legacy 的三个分支升至 4.155/4.132/2.568, 却没有带来 grounding 优势。因此当前 Norm 只作为训练稳定性与尺度健康项, 不能被解释为 target specificity 指标, 也没有证据支持增加更多 norm 模式。

7 Hallucination: 当前发现与局限

Target hallucination 是本项目和潜在审稿中最关键的问题之一: 若图中不存在 z , 但 Adapter 仍根据 target 文本生成看似匹配的 D , 工具就从“视觉证据提取器”退化为“target 条件生成器”。当前证据既发现了这一风险, 也暴露了评测本身尚不成熟。

图 2(a) 是最直接的失败例。对 C-T1, 正 target “球裤区域”在 free continuation 中输出 PRESENT; 但负 target “机车车体”也输出 PRESENT, 并生成 “locomotive body and side panels are visible” 的虚假描述。这个单例明确证明: 最佳 checkpoint 仍会发生 target hallucination, 平均指标不能掩盖它。

同时, teacher-forced log-odds 与自由生成并不总一致。该负 target 的 r^- 仍为负, 但 greedy continuation 却输出 PRESENT。五个 checkpoint 的绝对 actual_direction_accuracy 与 negative_false_positive_rate 都被强烈标签先验压成 0, 尽管 pairwise separation、自由生成和人工观察显示显著差异。因此本文使用 $r^+ - r^-$ 作相对诊断, 但不把零阈值指标当作有效结论。

当前验证还有以下限制:

1. 只有 36 个 same-image presence pairs 与 9 个 cross-image pairs, 覆盖面、置信区间和随机种子都不足;
2. negative target 由人工构造且通常语义差异很大, 未系统匹配长度、词频、视觉类别、局部位置和 hard-negative 难度;
3. PRESENT/NOT_PRESENT 的 base-model label prior 未校准, 严格字符串抽取会混合 grounding、格式遵循和 OCR/生成错误;
4. teacher-forced mean token log-prob、greedy continuation 与真正的 tool-use downstream behavior 不是同一测量对象;
5. pair 由开发阶段人工审计, 没有独立 blind annotation、inter-annotator agreement 或外部 benchmark protocol;
6. 同一个冻结 8B reader 既定义训练可读性又参与评测, 尚不能排除 reader-specific co-adaptation。

因此, 这套 audited diagnostics 的适当定位是轻量、初步、用于发现失败和筛选 checkpoint。它不是规范 hallucination benchmark, 也不能支持“方法解决了 hallucination”的论文主张。后续应单独设计更大、更难、盲审且经过 calibration 的 target-existence/target-content benchmark, 并明确区分视觉不存在、属性错误、关系错误、位置错误和 target-text leakage; 还应联合报告 teacher-forced intervention、自由生成与最终任务行为。该工作很重要, 但不在本报告阶段执行, 也不在此处提前冻结具体方案。


8 正确性证据与可复现性

当前实现的主要 correctness gates 包括:


- 原生 Qwen transcript round trip、无 tokenizer growth、无重复 think opener;
- target span、canonical/model token mapping 与 contextual H_z identity;
- 两种 conditioning providers 经过同一 typed Adapter boundary;
- Matrix-CE 的 length balance、legacy 保真和 streaming/manual-gradient 对 autograd parity;
- main D 与所有 D-DeepStack 分支作为同一 ob-



(a) 同图 target presence: 球棒存在，机车不存在。



(b) 固定 target “最高柱及年份”，正确 value 为 2017。



(c) 同一 target 在另一图中应翻转为 2019。

图 2: Audited grounding 的实际样例。图 (a) 对同一视觉输入使用正/负 target; 图 (b)(c) 固定 query/target, 只要求 D 随图像携带不同 value。图片仅用于解释已执行测试, 不扩充 evaluation population。

表 2: 同分布 target specificity 与 evidence readability。Top-1/MRR 越高越好; gap 与 wrong-same advantage 越大表示 correct D 和同图错误 D 分离越强; correct- D NLL 越低越好。

Checkpoint	Top-1	MRR	Mean gap	Correct- D NLL	Wrong-same win / advantage
C-T1	82.5%	0.906	2.431	1.286	93.5% / 4.643
E-T1	70.5%	0.833	0.773	1.292	86.0% / 2.113
C-Legacy	86.0%	0.925	0.308	1.376	94.0% / 0.571
C-Main	50.0%	0.701	0.053	1.293	74.5% / 0.234
C-T0.1	85.5%	0.919	0.419	1.260	94.5% / 0.748

表 3: Audited causal grounding。Cross/target continuation 分母分别为 18/72; 所有 healthy termination 均不低于 70/72。Presence separation 大于 0 才是期望方向。

Checkpoint	Cross flip	Cross continuation	Presence separation	Target continuation
C-T1	5/9	10/18	+0.407	39/72
E-T1	2/9	9/18	-2.283	10/72
C-Legacy	1/9	5/18	-0.968	4/72
C-Main	5/9	11/18	+0.958	6/72
C-T0.1	1/9	6/18	-1.600	27/72

表 4: 五份 immutable internal-evaluation report。SHA256 为报告文件 hash; checkpoint identity 为 artifact manifest identity; 表中均作首尾缩写。

ID	Checkpoint identity	Report SHA256	主要变量
C-T1	dfa992fc...e10	4fcd6faa...704	contextual, Balanced $T = 1$, full DS
E-T1	3ccc99e...469	af6b5d2f...9e3	target embedding, Balanced $T = 1$, full DS
C-Legacy	bc5b78c2...5b7f	7308f053...6bb	contextual, summed-NLL, full DS
C-Main	c80c616c...fc8b	54674da3...492	contextual, Balanced $T = 1$, main D only
C-T0.1	3ff14e66...f49e	02e299f3...baa	contextual, Balanced $T = 0.1$, full DS

servation 原子交换;

- evidence queries 屏蔽原图 keys, correct/wrong/random/no- D 控制共享同一 token/mask contract;
- 两卡 FSDP2 accumulation、global numerator/count reduction、checkpoint tear-down/resume 与 Adapter-only export;
- artifact、数据、prompt、processor、provider、branch layout 和 projection identity 的严格绑定。

五份 report 共享 data-manifest identity 534f5b1e...6b0、model identity 73334646...57c、prompt hash bf085a6e...3c9、seed 42, 以及 grounding manifest file SHA256 a65aa6e6...8c0。图像 provenance 与原始文件 hash 记录在 reports/figures/PROVENANCE.md。

9 结论

当前 representation phase 已形成一条闭合的原始 Qwen 训练路径: 从 tool-call target span 提取 H_z , 以双向 target-vision attention 调制主视觉与三个 DeepStack 分支, 经冻结 Qwen merger 生成完整 latent observation, 再用同图 Matrix CE 约束 target specificity、用 L_{gen} 约束因果可读性。训练不扩展 tokenizer、不更新 Qwen, 也不借用历史 checkpoint 初始化。

五个 2,000-step checkpoint 的统一比较支持三项选择: contextual hidden state 优于 target-token embedding; Balanced $T = 1$ 优于 legacy summed-NLL 和 $T = 0.1$ 的表面高 Top-1; 完整 D-DeepStack 对丰富 target-specific evidence 必不可少。因此 C-T1 是当前进入 policy RL phase 的 representation artifact 选择。

该选择不是 hallucination 问题的终点。最佳 checkpoint 仍在清晰不存在的 target 上生成虚假证据; 现有 36+9 pair 测试又过小且存在 label-prior 与测量不一致。最准确的结论是: 当前方法已经证明 D 可读、同图可分, 并取得有限的 causal grounding evidence, 但尚未证明对不存在 target 的稳健拒绝。后续独立 hallucination study 是进入更强方法主张前的必要工作。